

Classificação de Imagens Manuscritas com KNN e SVM

Artur P. Prata¹

¹Departamento de Computação – Universidade Tecnológica Federal do Paraná (UTFPR)
Caixa Postal 271 – 87301-899 – Campo Mourão – PR – Brazil

arturprata@alunos.utfpr.edu.br

1. Informações Gerais

Este artigo apresenta um estudo de classificação de imagens manuscritas com ênfase na avaliação de modelos de aprendizado supervisionado. Foram utilizados dois classificadores amplamente consolidados na literatura: o k-Nearest Neighbors (KNN) e o Support Vector Machine (SVM). Para fornecer entrada adequada a esses modelos, aplicaram-se técnicas de extração de características como LBP (Local Binary Patterns) e HOG (Histogram of Oriented Gradients), com o objetivo de representar a textura das imagens de forma eficiente. O foco da análise está na comparação direta entre os desempenhos dos classificadores, investigando como cada um responde a diferentes representações das imagens.

2. Introdução

A classificação de padrões manuscritos é uma tarefa importante na área de Visão Computacional, com aplicações que vão desde a digitalização de documentos até o reconhecimento automático de escrita. Um dos principais desafios nesse contexto é a escolha de modelos de classificação capazes de lidar com a variabilidade intrínseca da escrita humana.

Neste trabalho, investigamos o desempenho de dois algoritmos clássicos de aprendizado supervisionado: o k-Nearest Neighbors (KNN) e o Support Vector Machine (SVM), aplicados à tarefa de reconhecimento de nomes de meses escritos à mão. Ambos os modelos são amplamente utilizados em tarefas de classificação multiclasse, apresentando boas propriedades de generalização quando combinados com um conjunto adequado de características.

Para alimentar esses modelos, utilizamos dois descritores de textura: Local Binary Patterns (LBP) e Histogram of Oriented Gradients (HOG), que fornecem representações numéricas das imagens manuscritas. A base de dados utilizada contém 6000 imagens BMP, distribuídas uniformemente entre as 12 classes (meses do ano), o que permite uma avaliação consistente do desempenho dos modelos.

Os experimentos foram realizados com validação cruzada estratificada (5-fold) e os melhores hiperparâmetros foram encontrados por meio de busca em grade. O objetivo principal foi comparar o desempenho entre KNN e SVM, identificando qual modelo se adapta melhor ao problema proposto, independentemente do descritor utilizado.

Os resultados mostram diferenças marcantes de desempenho entre os modelos. O SVM, quando combinado com HOG, apresentou os melhores resultados de acurácia e F1-score, enquanto o KNN obteve desempenho inferior, especialmente com o descritor LBP. Esses achados reforçam a importância da escolha do classificador para alcançar bons resultados em problemas reais de classificação de padrões.

3. Metodologia

3.1. Base de Dados

A base utilizada contém 6000 imagens manuscritas (500 por mês), no formato BMP. Cada imagem foi rotulada com base no prefixo do nome do arquivo, representando os meses do ano.

3.2. Pré-processamento

As imagens foram convertidas para escala de cinza, redimensionadas para 96x96 pixels, com exceção do KNN com o uso do HOG, que foram redimensionadas para 128x128 pixels. Depois, foram submetidas à equalização de histograma. Em seguida, foram extraídas as características LBP ($P=24$, $R=4$, método: uniforme) ou HOG conforme o experimento.

3.3. Modelos e Avaliação

Os experimentos foram conduzidos com os classificadores KNN e SVM, combinados com os descritores LBP ou HOG. Utilizou-se validação cruzada estratificada (5-fold) e busca em grade para otimização de hiperparâmetros. A divisão treino/teste foi de 80/20.

4. Resultados

4.1. KNN com LBP

K: 9

Distância: Euclidian

Acurácia no conjunto de teste: 46% **F1-score médio macro:** 0.45

Tabela de Classificação:

Meses	Precision	Recall	F1-Score
Janeiro	0.41	0.37	0.39
Fevereiro	0.54	0.38	0.44
Março	0.37	0.31	0.34
Abril	0.52	0.65	0.58
Maio	0.44	0.30	0.36
Junho	0.34	0.28	0.31
Julho	0.46	0.50	0.48
Agosto	0.50	0.68	0.58
Setembro	0.34	0.27	0.30
Outubro	0.49	0.42	0.45
Novembro	0.73	0.71	0.72
Dezembro	0.37	0.63	0.46

Figure 1. KNN com LBP

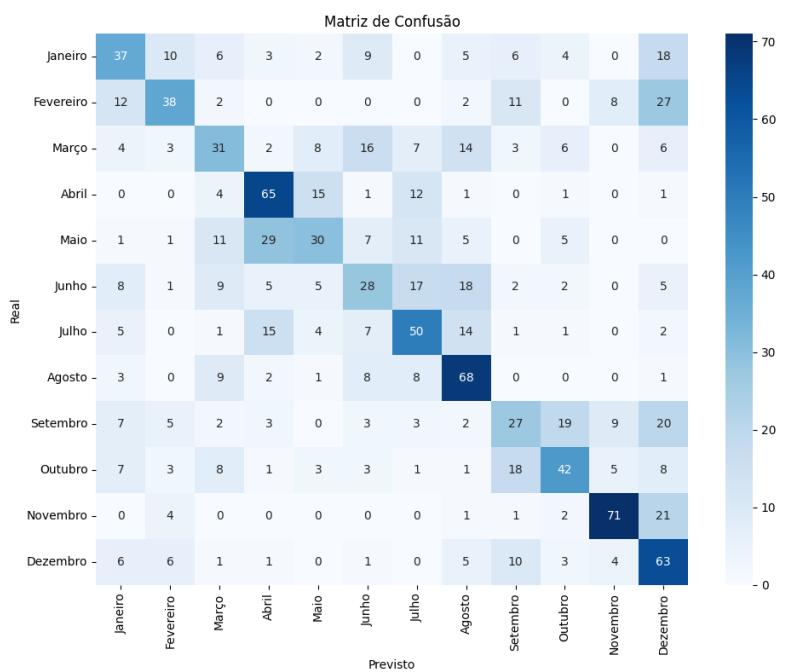


Figure 2. MC - KNN com LBP

4.2. SVM com LBP

Kernel: RBF

C: 10

Gamme: 0.01

Acurácia no conjunto de teste: 56%

F1-score médio macro: 0.56

Tabela de Classificação:

Meses	Precision	Recall	F1-Score
Janeiro	0.57	0.53	0.55
Fevereiro	0.64	0.61	0.62
Março	0.52	0.43	0.47
Abril	0.62	0.72	0.66
Maio	0.56	0.44	0.49
Junho	0.46	0.43	0.44
Julho	0.54	0.53	0.53
Agosto	0.56	0.75	0.64
Setembro	0.47	0.45	0.46
Outubro	0.53	0.54	0.54
Novembro	0.83	0.69	0.75
Dezembro	0.46	0.58	0.51

Figure 3. SVM com LBP

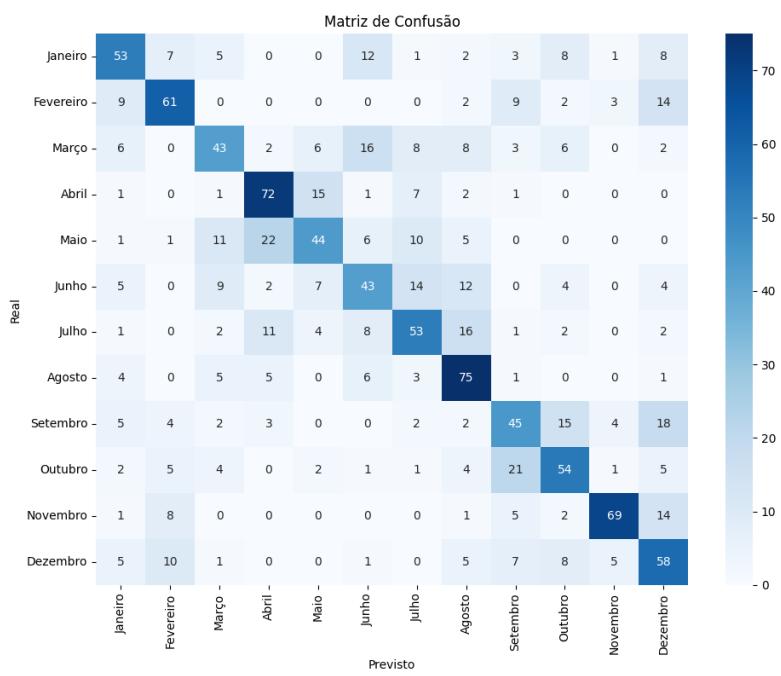


Figure 4. MC - SVM com LBP

4.3. KNN com HOG

K: 5

Distância: Euclidian

Acurácia no conjunto de teste: 74%

F1-score médio macro: 0.75

Tabela de Classificação:

Meses	Precision	Recall	F1-Score
Janeiro	0.67	0.58	0.62
Fevereiro	0.52	0.85	0.65
Março	0.96	0.93	0.94
Abril	0.95	0.78	0.86
Maio	0.93	0.57	0.71
Junho	0.74	0.52	0.61
Julho	0.87	0.72	0.79
Agosto	0.89	0.79	0.84
Setembro	0.79	0.70	0.74
Outubro	0.82	0.80	0.81
Novembro	0.52	0.92	0.66
Dezembro	0.72	0.76	0.74

Figure 5. KNN com HOG

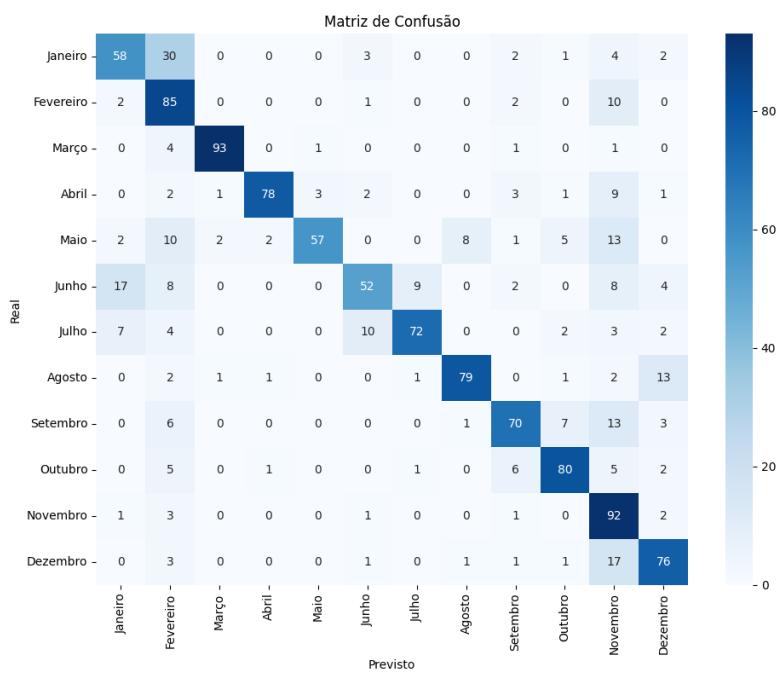


Figure 6. MC - KNN com HOG

4.4. SVM com HOG

Kernel: RBF

C: 10

Gamme: 0.001

Acurácia no conjunto de teste: 46%

F1-score médio macro: 0.45

Tabela de Classificação:

Meses	Precision	Recall	F1-Score
Janeiro	0.81	0.82	0.82
Fevereiro	0.82	0.89	0.86
Março	0.91	0.96	0.93
Abril	0.92	0.94	0.93
Maio	0.83	0.86	0.85
Junho	0.83	0.73	0.78
Julho	0.84	0.84	0.84
Agosto	0.93	0.93	0.93
Setembro	0.79	0.87	0.83
Outubro	0.91	0.86	0.88
Novembro	0.92	0.87	0.89
Dezembro	0.87	0.80	0.83

Figure 7. SVM com HOG

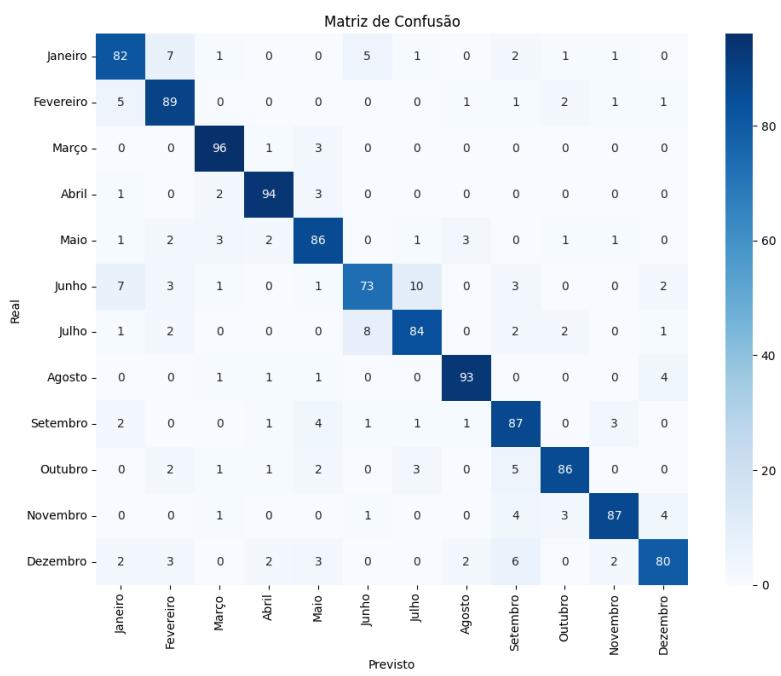


Figure 8. MC - SVM com HOG

5. Conclusão

Os resultados obtidos evidenciam a forte influência dos descritores de características sobre o desempenho dos classificadores. Embora o KNN seja um algoritmo simples e eficiente, seu desempenho variou substancialmente de acordo com a técnica de extração utilizada, apresentando limitações notáveis com o LBP. Por outro lado, a combinação do descritor HOG com o classificador SVM demonstrou-se significativamente superior, atingindo 86% de acurácia e F1-score macro, o que destaca sua robustez para tarefas de classificação multiclasse com imagens manuscritas. Como perspectivas futuras, sugere-se a exploração de arquiteturas baseadas em redes neurais convolucionais (CNNs), bem como estratégias de fusão de múltiplos descritores para potencial ganho de desempenho em cenários mais desafiadores.